

Computação Natural - Ant Colony Optimization Benchmark

Diogo Braga

University of Minho, Department of Informatics, 4710-057 Braga, Portugal
e-mail: {a82547}@alunos.uminho.pt

1 Introdução e conceção

O *benchmark* apresentado neste documento, relacionado com o algoritmo **Ant Colony Optimization**, coloca em análise a influência que, variáveis como a quantidade de feromonas ou a atratividade, têm no processo de aferição do melhor caminho existente de entre as opções do grafo. Essa influência acontece tanto no momento de **tomada de decisão de rota**, como no momento de **atualização do nível de feromonas**, sendo estes os momentos fulcrais do algoritmo. O objetivo principal do *benchmark* é verificar o comportamento das formigas até encontrarem o **caminho mais curto**.

Neste caso de estudo foi utilizado um grafo com 5 nodos, significando isto que existem 5 cidades. Os resultados disponibilizados neste documento aplicam-se sobre a seguinte matriz, que apresenta a distância entre diferentes cidades, no qual cada linha define a distância da cidade em questão para as restantes cidades.

$$\begin{pmatrix} 0 & 10 & 12 & 11 & 14 \\ 10 & 0 & 13 & 15 & 8 \\ 12 & 13 & 0 & 9 & 14 \\ 11 & 15 & 9 & 0 & 16 \\ 14 & 8 & 14 & 16 & 0 \end{pmatrix}$$

De forma a avaliar a convergência do modelo, foi assumido que o modelo se encontra em convergência quando mais que uma iteração possui o mesmo resultado. Em termos do algoritmo, isto significa que as formigas escolhem o melhor caminho em mais que uma ronda seguida.

2 Realização e resultados

Numa fase inicial, é realizada a análise com os valores pré-definidos, de forma a ter uma ideia geral no ponto de partida. Deste modo, vai ser possível avaliar a importância das variáveis nos dois momentos de cálculo fulcrais deste algoritmo, já referenciados na introdução.

Os valores pré-definidos são:

- **m (number of ants):** 5;
- **n (number of cities/nodes):** 5;
- **e (evaporation rate):** 0.5;
- **alpha (pheromone factor):** 1;
- **beta (attractiveness factor):** 2.

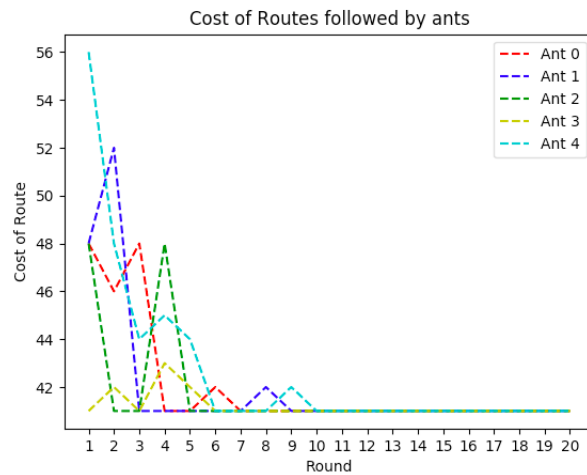


Fig. 1. Benchmarking com os valores pré-definidos

Deste gráfico podemos concluir que:

- Existe uma procura pelas melhores rotas (1^a até à 9^a iteração), que não é atingida;
- Na 10^a iteração, o custo do melhor caminho é igual a 41 e assim continua pelas restantes iterações, significando isto que esse é o resultado final da procura pelo melhor caminho;
- Melhor caminho: [1. 2. 5. 3. 4.].

2.1 Alteração do *pheromone factor*

Esta variável condiciona a influência que a quantidade de feromonas possui para os cálculos seguintes, isto é, encontra-se responsável pela influência que o histórico possui na escolha das rotas.




Fig. 2. Benchmarking com *pheromone factor* = 0.5

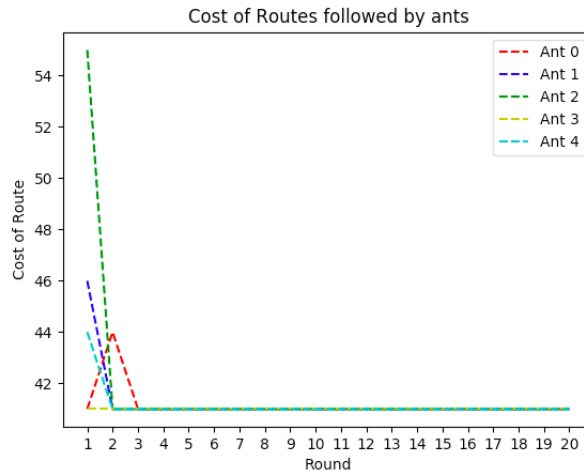


Fig. 3. Benchmarking com *pheromone factor* = 5

Destes gráficos podemos concluir que:

- Com valores baixos desta variável, a convergência entre as formigas torna-se difícil de atingir, notando-se apenas uma pequena proximidade a partir do episódio 10;
- Esta convergência reduzida acontece devido à pouca influência que as feromonas possuem nas iterações seguintes (histórico com pouca influência nas decisões);
- Melhor caminho (valores baixos da variável): [1. 2. 5. 3. 4.];
- Com valores elevados desta variável, a convergência acontece muito mais rápida, tendo ao episódio 3 já convergido e obtido o melhor caminho;
- Esta alta convergência acontece devido à elevada influência que as feromonas possuem nas iterações seguintes (histórico com muita influência nas decisões);
- Melhor caminho (valores elevados da variável): [1. 4. 3. 2. 5.].

2.2 Alteração do *attractiveness factor*

Esta variável condiciona a influência que a distância possui na escolha das rotas.




Fig. 4. Benchmarking com *attractiveness factor* = 0.5

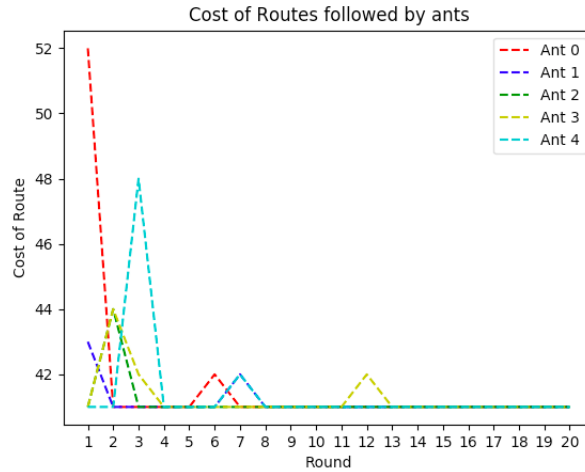


Fig. 5. Benchmarking com *attractiveness factor* = 5

Deste gráfico podemos concluir que:

- Com valores baixos desta variável, a convergência entre as formigas torna-se difícil de atingir, nem sendo atingido o custo mais baixo que tinha sido atingido com os valores pré-definidos (custo = 44);
- Esta baixa convergência acontece devido à pouca influência que as distâncias possuem no cálculo da tomada de decisão da rota, levando isto a que sejam mais vezes escolhidos rotas mais longas;
- Melhor caminho (valores baixos da variável) : [1. 3. 4. 2. 5.];
- Com valores elevados desta variável, a convergência acontece de forma muito mais rápida, tendo ao episódio 4 encontrado uma convergência, apesar de depois existirem mais umas pequenas variações (custo = 41);
- Esta alta convergência acontece devido à elevada influência que as distâncias possuem no momento do cálculo, levando isto a que caminhos mais curtos tenham mais influência na tomada de decisão;
- Melhor caminho (valores elevados da variável) : [1. 2. 5. 3. 4.].

3 Conclusão e principais dificuldades

Deste *benchmark* é possível concluir que, na generalidade dos casos, é encontrada a rota com o custo mais baixo. Na verdade, as diferenças nas variáveis provocam variações mas ao nível do tempo de convergência, sendo que, dependendo do problema, qualquer uma das variantes pode fazer sentido e ser a opção escolhida.

Importante também fazer referência ao *evaporation rate* que, de uma certa forma, ajusta a taxa de feromonas que queremos depositar em cada iteração. Tanto elevadas como baixas taxas são viáveis, dependendo essa influência da decisão do programador.

Em relação às dificuldades, referenciar que a resolução que tinha sido proposta nos links que o professor forneceu me causou alguma confusão, principalmente no momento do cálculo do custo do caminho ($d[int(best_route[-2]) - 1, 0]$). Apesar de entender que isso possa estar relacionado com o momento de voltar do nodo final para o inicial, achei melhor opção retirar essa parte, e realizar este benchmark em relação à procura do caminho mais curto.